


Systematic Evaluation of Single-Cell Foundation Model Interpretability Reveals Attention Captures Co-Expression Rather Than Unique Regulatory Signal

Kendiukhov et al., *Arxiv* (2026)

2026.02.25 Journal Meeting

변가은




KOREA
UNIVERSITY


Glossary

Attention은 생물학적 인과 관계를 반영하는가?


- 가정: 수백만 개의 세포로 훈련된 Transformer 모델이 생물학적 context를 학습 → 모델의 **attention map**을 분석하면, **GRN**을 도출할 수 있을 것이다.
- 현실: 이 가정은 NLP 분야에서도 논란이 되고 있으며, 생물학적으로 검증된 적 없음.



Attention



Cui et al. (scGPT)



Attention 은 생물학적 인과 관계를 반영하는가?

가정 1: 어텐션 패턴 = 인과적 조절 관계

- 우리의 착각: "모델이 유전자 A와 B를 연결해서 보고 있으니, 실제로 A가 B를 조절하는 거야."
- 현실: 이미 자연어 처리(NLP) 분야 연구에서도 ***"어텐션은 그냥 통계적 관계일 뿐, 인과적 중요도를 나타내지 않는다"***는 사실이 밝혀졌습니다. 이 논문은 생물학에서도 똑같은 일이 벌어지고 있음을 지적합니다.

가정 2: 빅데이터 = 더 나은 해석력 (질문하신 대목)

- 우리의 착각: "수백만 개의 세포를 학습했으니, 모델 내부의 조절 네트워크는 완벽할 거야."
- 현실: 데이터의 양보다 ***데이터의 질(이질성 관리)***이 해석력에 더 중요합니다. 무작정 데이터만 늘리면 오히려 신호가 묻개집니다.

가정 3: 어텐션 예측 = 실제 실험(CRISPR) 결과

- 우리의 착각: "어텐션 점수가 높은 유전자를 제거하면, 당연히 연결된 유전자들의 발현이 크게 변할 거야."
- 현실: 실제 CRISPR 섭동 데이터와 비교해 보니, 어텐션 점수와 실험 결과 사이에는 거의 상관관계가 없거나 매우 낮았습니다.

가정 4: 해석의 일반성 (Transferability)

- 우리의 착각: "간세포에서 찾은 조절 원리는 뉴런에서도 어느 정도 통할 거야."
- 현실: 기계론적 통찰은 생물학적 맥락(Context)에 따라 매우 민감하게 변하며, 한 곳에서 맞았다고 다른 곳에서 맞으리라는 보장이 없습니다.

Methods

검증 프레임 워크

Trivial-baseline
comparison


Conditional
incremental-value
testing

Confound control

Causal ablation

Cross-context
replication

1. 단순 기준선 비교



모델이 단순
통계보다 나은가?

2. 증분 가치 테스트




어텐션이 예측에
새로운 정보를
더하는가?

3. 잔차 분석




유전자 발현량을
통제해도 신호가
남는가?

4. 인과적 제거



중요 헤드를
제거하면 성능이
떨어지는가?

5. 교차 맥락 복제




다른 세포
유형에서도
재현되는가?

Results

Results1: Data scaling

데이터가 커질수록 성능이 하락함.

- **Experimental Design:** analyzed archived scGPT kidney scaling runs across three model tiers, three seeds, and varying cell counts (200, 1,000, and 3,000)
- **Network Construction:** Sparse Gene Regulatory Networks (GRNs) were constructed using attention-derived scores for directed gene pairs, specifically by retaining the top-100 targets for each source gene
- **Validation Method:** The recovered edges were evaluated against standard TRRUST and DoRothEA reference databases, with the evaluation restricted to the specific gene universe of each run



- 세포 수가 200 → 3000개로 증가함에 따라 GRN 복원 성능 (F1 Score)가 감소함.
- "Signal Dilution" : 단순한 데이터 증가는 Heterogeneity를 높여 Attention 신호를 흐린다.
- => 더 많은 데이터 != 더 높은 해석 가능성

Results1

CSSI : Cell State Stratification으로 representation을 향상시킬 수 있음.




Figure 1: **CSSI improves attention-derived GRN recovery.** CSSI-max TRRUST F1 versus number of strata (K) on DLPFC brain data. Stratified scoring improves recovery up to 1.85 $\times$ over unstratified baselines, with optimal $K = 5-7$.

- 기존의 데이터 pooling이 신호를 희석시킴.
- 세포 상태별로 임베딩 상에서의 Clustering → local한 추론 후 결과 통합 방식
- F1 score가 최대 1.85배 향상

Result 2: Trivial-baseline comparison

단순 통계 기반 분석이 딥러닝 모델을 능가하며, Co-expression 이상을 보지 못함.





Figure 2: **Gene-level baselines outperform pairwise edge scores.** AUROC for predicting CRISPRi perturbation targets using gene-level features (variance, mean expression, dropout rate) versus correlation-based edge scores ($n = 151$ perturbations; attention comparison in text). All gene-level baselines significantly outperform both edge types ($p < 10^{-12}$).

- Transformer 모델이 복잡한 조절 관계를 학습한 것이 아니라 **변동이 큰 유전자**를 찾음.
- 모델이 인과적 조절을 학습했다는 증거가 부재함. Confounds만을 학습

Result 3: Conditional incremental-value testing

Transformer 모델이 새로운 정보를 더하지 않음.

Gene-level features only:
평균 발현량, 분산(Variance), 드롭아웃 비율 등 단순 통계값







- A key question is whether pairwise edge scores—attention or correlation—add predictive value beyond gene level features for identifying perturbation targets.
- Gene feature에 Attention score를 추가하여 예측력 변화 측정 (Perturbation-outcome binary classification).
- Corr. Attn 간 Δ AUROC = -0.0004
- => Attention이 제공하는 정보는 이미 기본 유전자 통계에 모두 포함이 되어 있으며, 유전자 쌍에 대한 추가적인 정보가 없음.

Result 4: Causal ablation




중요한 헤드를 꺼도 결과에 영향을 끼치지 않음.

- 유전자 조절을 담당한다고 모델이 추정한 상위 50개 헤드를 제거
- Results:** 성능 저하 0 %
- => 모델의 예측 능력은 특정 Attention 패턴에 의존하지 않음.
- Random Heads가 Regulatory head보다 제거 시 성능 하락에 더 큰 영향을 끼침.
- FFN의 출력값을 지웠을 때는(MLP ablation) 모델의 연산 기능이 망가지는 현상이 관찰됨.



Result 5

RPE1 세포 Attention 분석, Residualization 시 해당 attention의 88%가 사라짐.



Result 6

그러면 모델은 무엇을 학습했나?

- 초기 Layer : PPI
- 후기 Layer : Transcriptional Regulation
- 즉, 모델이 생물학적 구조 자체는 학습하지만, Perturbation에 대한 인과적 예측으로 이어지지 않음.

Table S12: **AUROC of Geneformer attention edges against six biological reference databases across all 18 layers.** Correlation baseline shown in last row.

Layer	STRING _{≥700}	STRING _{≥900}	TRRUST	Reactome	KEGG	GO BP
L0	0.640	0.644	0.558	0.505	0.530	0.526
L1	0.517	0.501	0.691	0.501	0.484	0.501
L4	0.546	0.530	0.686	0.516	0.525	0.515
L8	0.530	0.519	0.631	0.509	0.531	0.534
L13	0.574	0.559	0.708	0.523	0.548	0.530
L15	0.525	0.500	0.750	0.521	0.555	0.541
L16	0.475	0.457	0.733	0.516	0.564	0.544
L17	0.485	0.460	0.664	0.516	0.539	0.541
Corr.	0.562	0.559	0.649	0.514	0.541	0.513

STRING: PPI network

GO BP : Regulatory Pathways

Discussion

Summary / Discussion

Summary


- 생물학적인 유전자 고유의 성질이 관계성보다 예측에 더 중요했다
- Attention의 추가적인 가치는 0임
- 중요한 head를 제거해도 모델이 영향을 받지 않음 (인과성의 부재)

Dicussion


- 특정 기능을 수행하는 헤드(circuit)가 명확히 존재하는 자연어 처리(NLP) 모델과는 다른 양상으로, 단일 세포 모델에서는 특정 '조절 회로'가 예측을 전담하지 않음.
- Attention → Jacobian : 다변수 함수의 미분(기울기)을 행렬 형태로 나타내어 모든 Attention, 모든 MLP, 모든 잔차 연결(Residual Connection)을 Chain Rule을 통해 한 줄의 식으로 엮어냄.

비교 항목	Attention Weight (기존)	Jacobian (새로운 방법)
핵심 질문	"유전자 i 가 j 를 얼마나 참조하는가?"	"유전자 j 가 변하면 i 는 얼마나 변하는가?"
통계적 의미	상관관계, 공발현 (Co-expression)	인과적 민감도 (Causal Sensitivity)
계산 범위	특정 레이어의 어텐션 모듈에 국한	모델 전체 레이어 (End-to-End)
생물학적 비유	세포 내 유전자들이 '함께 있는' 사진	유전자 하나를 건드렸을 때의 '연쇄 반응' 시뮬레이션
장점	계산이 빠르고 직관적임	모델이 배운 진짜 '조절 로직'을 추출함

Jacobian vs Attention: Marker Gene Recovery (AUROC)



Top 20 Genes per Cell Type: Attention vs Jacobian



레이어 전체를 관통하는 누적 정보 흐름이 어느 단일 레이어보다 생물학적으로 풍부함?