

Reinforcement learning-based design of sequential drug treatment targeting the evolving tumour landscape with SequenTx

Chen et al., *Nature Machine Intel.* (2026)

2026.02.25 Journal Meeting

변가은




KOREA
UNIVERSITY

Background & Motivation

Sequential therapy 설계의 필요성

Oncology에서의 사전 연구) 종양의 상태는 치료 중 Static 하지 않음을 감안하여 “One-two punch” 전략을 사용

- 특정 유전적 전사 프로그램의 안정적인 억제 또는 활성화는 정상 세포가 신생 종양 세포 운명으로 변환되는 것을 유도함. → 약물 치료 타겟
- 암 진행 및 치료 중에 종양 세포는 다른 세포 상태 간의 동적 전환을 겪으며, 약물 감수성이 상이해짐.
- 이러한 치료 유도 전사 변화의 지속, 즉 정적인 치료는 약물 내성으로 이어질 수 있는 위험이 존재.
- 치료 순서와 타이밍이 치료 효과에 결정적 영향을 미친다!




Background & Motivation

Sequential therapy 설계의 필요성

Oncology에서의 사전 연구) 종양의 상태는 치료 중 Static 하지 않음을 감안하여 “One-two punch” 전략을 사용

- 특정 유전적 전사 프로그램의 안정적인 억제 또는 활성화는 정상 세포가 신생 종양 세포 운명으로 변환되는 것을 유도함. → 약물 치료 타겟
- 암 진행 및 치료 중에 종양 세포는 다른 세포 상태 간의 동적 전환을 겪으며, 약물 감수성이 상이해짐.
- 이러한 치료 유도 전사 변화의 지속, 즉 정적인 치료는 약물 내성으로 이어질 수 있는 위험이 존재.
- 치료 순서와 타이밍이 치료 효과에 결정적 영향을 미친다!


However, recent experimental studies, have focused on a narrow range of drugs, tumour types and cellular states, have been limited in scope, thereby **an applicable computational framework is needed.**




Background & Motivation

AIVC의 등장: *in silico* simulation of sequential therapy 의 가능성 대두


- Recent advancements in AIVC tech., such as STATE and SToFM, have revolutionized the simulation of such complex cellular dynamics.



STATE (Adduri et al.(2025))



SToFM (Zhao et al.(2025))



Background & Motivation

Reinforcement Learning



- State : 특정 환경 내 상태를 의미한다.
- Agent : 모델 혹은 AI가 된다.
- Reward : 보상을 의미한다.
- Action : Agent가 취할 행동을 의미한다.
- Policy : 특정 state에서의 최대 보상을 제공하는 action을 정하는 알고리즘이다.

$$Q(s, a) = r + \max_{a'} Q(s', a')$$

Optimal Policy

$$\Pi(s) = \arg \max_a Q(s, a)$$



MAX Q

$$MAX Q = \max_{a'} Q(s, a')$$

특정 state에서의 실제 최대 보상 Optimal Policy ($\Pi(s)$) 와 Agent가 선택한 action에 따른 최대 보상 MAX Q의 차이가 최소화되도록 학습


Background & Motivation Reinforcement Learning

Tumour cell model



SequenTx Model Architecture

Modelling reward




- Changes in tumour cell state, expression profile and cell count during the drug regimen $A^n B^m$.
- **Efficacy reward $R_e(A^n B^m)$:** 최종적으로 종양 세포가 얼마나 줄어들었는지를 측정
- **Sequential synergy reward $R_s(A^n B^m)$:** 약물을 따로 쓰는 것보다 순서대로 썼을 때 얻는 추가 이득이 얼마인가?

Episode reward, $R = R_s + R_e$ 를 최대화하도록 학습


Markov Decision Process (MDP) Workflow

- 순차적 의사결정 문제 (MDP) 정의를 통해 앞선 강화 학습 프로세스를 sequential therapy에 적용 가능하도록 공식화

S (States)	A (Actions)	T (Transition)	R (Reward)	π (Policy)
종양 세포주의 유전자 발현 프로파일 978 landmark genes (L1000)	Small molecule 화합물 166-dim binary fingerprint encoding	function f_T Drug 투여 후 다음 전사체 상태 예측	Efficacy reward + Synergy reward	RL agent가 학습하는 함수 현재 세포 상태 $\rightarrow$ 투여할 약물 선택




c




SequenTx Model Architecture

Environment : Transition Function/ Prediction function


f_T 신경망 구조




전사체 프로파일 (978 genes)
+ 화합물 fingerprint (166 dims)
= 1,144 차원



두 입력을 별도 FC layer로 처리
• 전사체: 978 nodes
• 화합물: 166 nodes




Concatenate → 512 nodes
Sigmoid activation (모든 FC layer)



978 nodes
→ 약물 투여 후 전사체 변화량 (Δs)


f_P 신경망 구조




f_T 출력 (약물 투여 후 전사체 변화량 (Δs))




- 입력: f_T 가 예측한 전사체 변화량 (L1000)
- 학습 데이터: CTRPV2 세포 생존율 + LINCS L1000 발현
- 6h, 24h, 48h 시점 데이터 모두 활용



- 초기 세포 수 = 100 (정규화)
- cv_i : time step i 에서 f_P 가 예측한 생존율
- 각 step의 cv 를 연속 곱 → 누적 세포 감소 추적
- RL agent의 environment로 작동



$cv_t \rightarrow R_e$



Data

LINC-L1000


- 159,339 샘플 (7,964 약물 × 30 세포주)
- 조건: 9–11 μM, 24h 노출
- 입력: pretreatment 전사체 + 화합물 fingerprint
- 출력: posttreatment 전사체 변화량
- Expression Strength(ES) < 0.1 샘플 제거

Ligands

1



2




3




...

n



Interact

Protein



MACCSL: 166 bits MACCS fingerprints for ligands

0	1	1	0	1	0	...	1	0	0
---	---	---	---	---	---	-----	---	---	---

1	0	0	0	0	1	...	0	0	1
---	---	---	---	---	---	-----	---	---	---

0	0	1	1	0	0	...	0	1	1
---	---	---	---	---	---	-----	---	---	---

...	...	...	...	...	...	...	...	...	...
-----	-----	-----	-----	-----	-----	-----	-----	-----	-----

1	0	0	0	0	0	...	1	1	1
---	---	---	---	---	---	-----	---	---	---

$$MACCSP = \frac{\sum_i MACCSL}{n}$$

MACCSP

0.152	0.322	0	0	0	1	...	0	0	1
-------	-------	---	---	---	---	-----	---	---	---

ARTICLE OPEN

L1000CDS²: LINCS L1000 characteristic direction signatures search engine

Qiaonan Duan^{1,2,5}, St Patrick Reid^{3,5}, Neil R Clark^{1,2}, Zichen Wang^{1,2}, Nicolas F Fernandez^{1,2}, Andrew D Rouillard^{1,2}, Ben Readhead², Sarah R Tritsch³, Rachel Hodos², Marc Hafner⁴, Mario Niepel⁴, Peter K Sorger⁴, Joel T Dudley², Sina Bavari³, Rekha G Panchal³ and Avi Ma'ayan^{1,2}

The library of integrated network-based cellular signatures (LINCS) L1000 data set currently comprises of over a million gene expression profiles of chemically perturbed human cell lines. Through unique several intrinsic and extrinsic benchmarking schemes, we demonstrate that processing the L1000 data with the characteristic direction (CD) method significantly improves signal to noise compared with the MODZ method currently used to compute L1000 signatures. The CD processed L1000 signatures are served through a state-of-the-art web-based search engine application called L1000CDS². The L1000CDS² search engine provides prioritization of thousands of small-molecule signatures, and their pairwise combinations, predicted to either mimic or reverse an input gene expression signature using two methods. The L1000CDS² search engine also predicts drug targets for all the small molecules profiled by the L1000 assay that we processed. Targets are predicted by computing the cosine similarity between the L1000 small-molecule signatures and a large collection of signatures extracted from the gene expression omnibus (GEO) for single-gene perturbations in mammalian cells. We applied L1000CDS² to prioritize small molecules that are predicted to reverse expression in 670 disease signatures also extracted from GEO, and prioritized small molecules that can mimic expression of 22 endogenous ligand signatures profiled by the L1000 assay. As a case study, to further demonstrate the utility of L1000CDS², we collected expression signatures from human cells infected with Ebola virus at 30, 60 and 120 min. Querying these signatures with L1000CDS² we identified kenpaullone, a GSK3B/CDK2 inhibitor that we show, in subsequent experiments, has a dose-dependent efficacy in inhibiting Ebola infection *in vitro* without causing cellular toxicity in human cell lines. In summary, the L1000CDS² tool can be applied in many biological and biomedical settings, while improving the extraction of knowledge from the LINCS L1000 resource.


npj Systems Biology and Applications (2016) **2**, 16015; doi:10.1038/npjbsa.2016.15; published online 4 August 2016

Results


SequenTx Model Evaluation

f_T 가 전사체 변화를 얼마나 정확하게 예측하나?

a



b






약물 유형 및 세포주별 성능 분포

-
- c**
- PCC
- PCL members
- MDM inhibitor, HDAC inhibitor, HIF activator, Tachykinin receptor antagonist, Protease inhibitor, Sigma receptor antagonist, Angiotensin receptor antagonist, ATP synthase inhibitor, Topoisomerase inhibitor, Bacterial cell-wall synthesis inhibitor





SequenTx Model Evaluation

Erlotinib + doxorubicin HCl





- (1) How does the duration of drug A influence drug B efficacy in sequential therapy?
- (2) Which tumour states are crucial for sequential synergy?
- (3) Is there a preference for specific drug types among the first drugs in sequential drug treatments?



$A^{10}B^{10}$ 에 대한 matrix



- (1) How does the duration of drug A influence drug B efficacy in sequential therapy?
- (2) Which tumour states are crucial for sequential synergy?
- (3) Is there a preference for specific drug types among the first drugs in sequential drug treatments?



class 1 (no trend), **class 2 (monotonic increasing)**, **class 3 (monotonic decreasing)**, **class 4 (increasing then decreasing)**, **class 5 (decreasing then increasing)**, class 6 (increasing then decreasing then increasing) and class 7 (decreasing then increasing then decreasing).


- (1) How does the duration of drug A influence drug B efficacy in sequential therapy?
- (2) Which tumour states are crucial for sequential synergy?
- (3) Is there a preference for specific drug types among the first drugs in sequential drug treatments?

전사 재구성(transcriptional reprogramming)과 크로마틴 구조의 변화를 유도하는 약물 타입들




in vitro validation

- we conducted a large-scale in vitro screen across six cancer cell lines and mechanistically diverse drugs, which assessed a panel of 102 sequential drug combinations prioritized by SequenTx from the FDA-approved anticancer drug pool.
- HSA(HSA synergy score):** 서로 다른 두 약물을 같이 쓸 때의 시너지 정도를, 각 약물 단독 효과와 비교해 측정하는 지표
- for combinations in which the first drug was known to directly induce transcriptional changes, the success rate rose to 42%
- the forward treatment sequence (AnBm) exerted a stronger inhibitory effect on tumour cell growth than the reverse order (BmAn), which further validated the synergistic effect of sequential combinations (Extended Data Fig. 6g–j).



A sequential drug combination of I-BET726 and oxaliplatin for melanoma treatment



Discussion

Limitation

- **unseen cell line에 대한 일반화 한계**
 - 새로운 세포주에 대해 상태 전이 모델의 예측 정확도가 크게 떨어질 수 있음(Zero-shot of cell line에서 PCC 낮음).
 - 약물마다 유효 농도 범위가 다르고 투여 간격도 다양한 임상 환경 반영 못함.
- **데이터 의존성 및 범위 제한**
 - 모델 학습과 검증이 주로 LINC1166(978개 유전자)와 24h perturbation 데이터에 의존해 있어 시간 확장성 및 다시한 포인트 예측의 신뢰도가 제한될 수 있음.
- **환경의 단순화/가상화의 한계**
 - Tumour cell model이 실제 환자 생체환경(마이크로환경, 면역 시스템, 혈관 구조 등)을 충분히 반영하지 못할 수 있음.
 - AIVC의 전이 함수 f_T , 예측 함수 f_P 의 근거가 주로 bulk 데이터에 의존
- **시간 해상도 및 외삽의 제약**
 - 학습은 24시간 간격으로 설계되어 있어 24h 이상의 긴 시간 스케줄링이나 빠른 시간 스케일의 반응을 포착하는 데 제한이 있을 수 있음.
 - 48시간 이상의 예측 확장이 보편적이지 않아 장기적 반응 예측의 불확실성이 큼.
- **약물 풀의 제한성**
 - FDA 승인 약물 풀 및 특정 에피제네틱 약물에 집중되어 있어 미승인 약물이나 새로운 화합물의 탐색 공간이 좁을 수 있음.
- **해석성과 투명성의 문제**
 - RL 접근은 정책의 해석이 어려울 수 있어 임상 적용 시 의사결정의 투명성과 안전성 확보가 도전적임.

강화학습 기법 적용해보기

Inverse Reinforcement Learning, IRL

현실세계 문제를 강화학습으로 풀고자 할 경우, 가장 중요한 것은 Reward shaping이다.

보상을 어떻게 정의할 것인가에 대한 문제인데, 보상을 어떻게 정의하느냐에 따라 action이나 policy 모두 달라지기 때문이다.

하지만 현실에서 보상을 수치로 환산하는 것이 매우 어렵다.

예를 들어 금전적인 보상을 받는 것이 아닌, 유저의 최대 만족감을 보장하는 최적의 선택을 학습하고 싶을 경우가 그렇다.

이럴 땐 비물질적인 가치를 수치로 어떻게 환산하느냐가 문제가 된다.

이에 따라 보상을 역으로 모든 상황을 관찰(observation)한 후, 역으로 수치화하는 강화학습 방법이 떠오르고 있다.

IRL(Inverse Reinforcement Learning)이라고 부른다.

일반적인 강화 학습은 모델에 보상을 설계하여 input한 뒤 최적의 policy π 를 배워나가지만,

IRL은 반대로 Optimal policy π 를 바탕으로 보상을 재설계하는 방식이다.

Imitation Learning

다른 강화학습 트렌드는 모방학습인데, imitation learning이라 불린다.

Imitation learning이 가장 활발하게 사용되는 것은 자율주행이라고 한다.

그 이유는 action이 핸들을 조정하고, 브레이크 밟는다 정도로 두 개 밖에 되지 않기 때문이다.

가장 단순한 형태로 action을 표현할 수 있어서 활발히 연구되고 있다.

Multi-agent learning

앞서 살펴본 강화학습에 대한 예시는 모두 single agent를 가정하고 있다.

Agent가 여러 명일 때에도 강화학습을 적용할 수 있다.

예를 들어 게임에서 여러 명의 플레이어가 공동의 목표를 달성하기 위해 전략을 각기 수행해야한다고 생각해보자.

이 때 앞서 살펴본 single agent 방식을 적용하게 되면 모든 agent가 자신의 보상을 최대화하기 위해 이기적으로 행동할 것이고, 결국 엉망된다.

공동의 보상을 달성하기 위해서는 Agent는 상황에 따라 양보도 해야하고, 협력도 해야한다.

Multi-agent learning은 네트워크/통신에 가장 많이 활용되는 강화학습이다.

트래픽이 한 곳으로 집중될 때, 안정적인 네트워크 망 환경을 유지하기 위해 어느 쪽으로 트래픽이 나뉘어야하는지 등을 풀 때 사용된다.