

Learning biophysical models of gene regulation with probability flow matching

Maddu, Chardès & Shelley, arXiv:2604.25062 (2026)


2026. 08. 12 Journal Meeting 변가은

Introduction

Gene expression is an intrinsically stochastic biochemical process

- Transcription = **chromatin opening** → **TF binding** → **polymerase recruitment** → **RNA 생성/분해**의 연쇄 확률 과정
- **scATAC-seq / scRNA-seq**는 이 과정의 정적 snapshot만 제공+ RNA 개수는 본질적으로 discrete, noisy
- 따라서 세포 하나의 상태 $x(t)$ 는 결정론적 궤적이 아니라 **확률분포 $p(x,t)$** 의 진화로 기술해야 함

(a) Single-cell measurements + biophysical model of gene expression




Introduction

Snapshot 데이터로부터 latent stochastic dynamics를 복원하는 문제

- **Cross-sectional snapshot** : 서로 다른 시점에서 서로 다른 세포를 측정 (같은 세포를 추적할 수 없음)

→ 관측되는 것은 각 시점의 주변분포(Marginal dist.) $p_t(x)$ 뿐, 궤적은 관측 불가 → **Inverse problem**

(b) Cell distribution differentiation change over time



Introduction

Inverse Problem and Identifiability

- 데이터를 얼마나 잘 맞추느냐(Interpolation accuracy)가 모델의 생물학적 타당성을 보장하지 않는다
- TrajectoryNet vs CLE
 - **TrajectoryNet, TIGON** : ODE
 - **Chemical Langevin Model (CLE)**
 - 고정된 유전자 조절 법칙($h(x)$)을 따르며, 생물리학적 원리에 기반한 노이즈(확산)를 포함하게 함.

Introduction

기존 방법들은 scalability와 biophysical consistency를 맞바꿈

Method	동작 공간	Stochasticity	한계 / 특징
Dynamical OT (TrajectoryNet, PRESCIENT)	저차원 latent (PCA)	$D(x) = 0$ 또는 등방성	기계론적 해석 불가, OOD 초기조건에 취약
RNA velocity	gene space	무시	유전자 간 조절 상호작용을 decoupled 로 가정
Flow Matching (FM)	gene space 가능	단순화된 noise, 두 marginal만	multi-marginal·임의 noise 확장 불가
PFI	gene space	intrinsic noise 명시	ODE·Wasserstein 반복 계산 → 수십 개 유전자가 한계
PFM	gene space (TF space)	임의 형태의 noise + 증식/사멸	simulation-free → 고차원까지 확장 가능

Method

PFM

- Chemical Langevin (CLE, Chemical Langevin Equation)형 SDE
 - Transcription을 생성 $h(x)$ 와 분해 ℓx 의 경쟁으로 기술
- PFM 은 이 SDE 를 반복 시뮬레이션하지 않고 **등가의 velocity field 를 회귀로 학습**

(c) A coarse-grained biophysical model of gene transcriptional dynamics:

Noise항

$$dx = (h(x) - \ell x) \Delta t + \sqrt{(h(x) + \ell x)} dw$$

x : cellular transcriptome

ℓ : mRNA degradation rate

W : Wiener process

$h(x)$: regulatory dynamics

$$f(x) = (h(x) - \ell x)$$

$$D(x) = \text{diag}(h(x) + \ell x)$$



(d) Probability Flow Matching

$$\mathcal{L}_{PFM}(\theta) := \mathbb{E}_{t \sim U[0, T], z \sim q(z), x \sim p_t(x|z)} [\|u_\theta(x, t) - u_t(x|z)\|^2]$$

$$u_\theta(x, t) = f_\theta(x) - \nabla \cdot D(x) - D(x) \nabla \log p_t(x)$$

score function

** Score function & Wiener process

- Eq (1)의 시간 기댓값을 수치적분할 때 쓰는 시간 격자의 조밀도

Method

Probability Flow Matching : simulation-free 3-step 추론

- **Step 1. Score estimation**

- 각 측정 시점에서 score function ($\nabla \log p_t(x)$)을 추정
- 이 때 Force는 모델링하지 않음.

- **Step 2. Conditional path**

- Multi-marginal OT coupling (MMOT) 으로 조건변수 z 를 샘플링하고 Gaussian 경로 $p_t(x|z) = N(x | Q_{t(z)}, \sigma^2)$ 구성
- Chebyshev interpolants 사용해 시점 사이를 연결

- **Step 3. Velocity regression**

- 아래 conditional flow matching 목적함수 ($\mathcal{L}_{CFM}$)로 velocity field 를 직접 회귀 (ODE/SDE solve 없음)

$$\mathcal{L}_{CFM} \equiv \mathbb{E}_{t,q(z)} \left[\frac{m_t(z)}{M_t} \mathbb{E}_{p_t(\mathbf{x}|z)} \left\| \mathbf{u}_t(\mathbf{x}|z) - \mathbf{u}_t^\theta(\mathbf{x}) \right\|^2 \right]. \quad (1)$$

$$\frac{\partial p_t(\mathbf{x})}{\partial t} = -\nabla \cdot (\mathbf{u}_t(\mathbf{x}) p_t(\mathbf{x})) + g_t(\mathbf{x}) p_t(\mathbf{x}), \quad \text{where}$$

$$\mathbf{u}_t(\mathbf{x}) = \mathbf{f}(\mathbf{x}) - \nabla \cdot \mathbf{D}(\mathbf{x}) - \mathbf{D}(\mathbf{x}) \nabla \log p_t(\mathbf{x}).$$

Method

1. Fokker–Planck Equation

$$\frac{\partial p_t(\mathbf{x})}{\partial t} = -\nabla \cdot (\mathbf{u}_t(\mathbf{x})p_t(\mathbf{x})) + g_t(\mathbf{x})p_t(\mathbf{x}), \quad \text{where}$$
$$\mathbf{u}_t(\mathbf{x}) = \mathbf{f}(\mathbf{x}) - \nabla \cdot \mathbf{D}(\mathbf{x}) - \mathbf{D}(\mathbf{x})\nabla \log p_t(\mathbf{x}).$$

$$\mathbf{f}(\mathbf{x}) = (\mathbf{h}(\mathbf{x}) - \ell\mathbf{x})$$

$$\mathbf{D}(\mathbf{x}) = \text{diag} (\mathbf{h}(\mathbf{x}) + \ell\mathbf{x})$$

- $\mathbf{f}(\mathbf{x})$ encodes gene-regulatory interactions,
- while $\mathbf{D}(\mathbf{x})=\mathbf{G}(\mathbf{x})\mathbf{G}(\mathbf{x})^\top$ is the diffusion matrix that captures intrinsic/extrinsic noise.
- $g_t(\mathbf{x})$ models cell proliferation and death

Method

1. Fokker–Planck Equation

모델 유형	$f(x)$ (Drift)	$D(x)$ (Diffusion)	특징
ODE	$h(x) - \ell x$	0	결정론적, 노이즈 없음
Additive	$h(x) - \ell x$	I (단위 행렬)	모든 방향으로 일정한 노이즈
Multiplicative	$h(x) - \ell x$	$\sqrt{x}$	발현량에 비례하는 노이즈
CLE	$h(x) - \ell x$	$\frac{1}{2}\text{diag}(h(x) + \ell x)$	생물리학적 일관성 (본 논문의 핵심)

Method

2. Cell Population dynamics

- 각 개별 세포(x_i)에 질량(m)이라는 가중치를 부여

$$\mathcal{L}_{\text{CFM}} \equiv \mathbb{E}_{t,q(\mathbf{z})} \left[\frac{m_t(\mathbf{z})}{M_t} \mathbb{E}_{p_t(\mathbf{x}|\mathbf{z})} \left\| \mathbf{u}_t(\mathbf{x}|\mathbf{z}) - \mathbf{u}_t^\theta(\mathbf{x}) \right\|^2 \right]. \quad (1)$$

$$p_{t_k}(\mathbf{x}) \approx \sum_{i=1}^{n_k} m_{t_k}(\mathbf{x}_{i,t_k}) \delta(\mathbf{x} - \mathbf{x}_{i,t_k}).$$

$$\dot{m}(\mu_t) = m(\mu_t)g(\mu_t)$$

Growth Rate


Method

3. Chebyshev conditional path

- 표준 FM 은 두 분포 사이 Brownian bridge
 - Multi-marginal 로 확장 시 piecewise-linear 평균 경로 를 쓰게 됨
 - 속도가 **piecewise-constant** 가 되어 데이터 시점에서 **불연속** 발생 → 회귀된 velocity field 에 artifact를 유발
- PFM 은 평균경로를 **Chebyshev 다항식** 으로 매개화
→ 전역적으로 매끄러운 시간 미분이 가능함.

Chebyshev vs Linear vs Cubic-spline


- 표준 FM 의 Brownian bridge 를 multi-marginal 로 확장하는 세 가지 방식
 → 조건부 평균경로 μ_t 를 무엇으로 두느냐가 회귀되는 velocity 를 결정




비교 항목	Linear (= Brownian bridge)	Cubic-spline	Chebyshev (PFM 채택)
평균경로 μ_t 매개화	구간별 선형	구간별 3차 다항식 (국소 보간)	전역 다항식 보간 (Chebyshev 노드)
시간 미분 = 조건부 속도	piecewise-constant 데이터 시점에서 불연속	구간 경계에서 연속 그러나 국소적	전역적으로 매끄러움
회귀된 velocity field	불연속 지점에서 artifact	artifact 완화	안정적, artifact 없음
고차원·저샘플 정확도 (b)	가장 낮음	중간	가장 높음
적분점 증가 시 수렴 (c)	느림	느림	가장 빠름

Result 1

Chebyshev interpolants




b Chebyshev Interpolation



$$\hat{\mathbf{B}} = \begin{bmatrix} 3.04 & -0.16 \\ -0.14 & 0.17 \end{bmatrix}$$

RMSE = 0.013


Cubic-Spline interpolation



$$\hat{\mathbf{B}} = \begin{bmatrix} 2.55 & -0.02 \\ -0.11 & 0.16 \end{bmatrix}$$

RMSE = 0.174

Linear Interpolation



$$\hat{\mathbf{B}} = \begin{bmatrix} 1.95 & 0.18 \\ -0.09 & 0.16 \end{bmatrix}$$


RMSE = 0.378

Referene velocity $\rightarrow \mathbf{u}_t(\mathbf{x})$ Probability flow velocity $\rightarrow \hat{\mathbf{u}}_t(\mathbf{x})$ Mismatch $\rightarrow \hat{\mathbf{u}}_t(\mathbf{x}) - \mathbf{u}_t(\mathbf{x})$

Result 1

Chebyshev interpolants


- high-dimensional nonlinear settings
 - We generate synthetic data in dimensions $d \in \{10, 20, 30, 40, 50\}$ and generate multi-marginal snapshot data at $K = 5$ time points.



- Quadrature 점수를 늘릴 때 수렴도 더 빠르게 수렴

** Quadrature factor

- Eq (1)의 시간 기댓값을 수치적분할 때 쓰는 시간 격자의 조밀도
- 크게 할수록 적분 오차가 줄어 추정치 참값에 수렴



Method

Algorithm 1 : Probability Flow Matching

Algorithm 1 Probability Flow matching

Input: K statistically independent marginals p_{t_k} sampled at successive times $t_0, t_1, \dots, t_{K-1}$.
Estimate score: $\mathbf{s}_\phi(\mathbf{x}, t) \approx \nabla \log p_t(\mathbf{x})$ using sliced-score matching as described in Eq. (C1) ▷ Precompute and freeze $\mathbf{s}_\phi$
while true do
 Sample batches of size B i.i.d. from the datasets
 $\mathbf{x}_0 \sim p_{t_0}, \mathbf{x}_1 \sim p_{t_1}, \dots, \mathbf{x}_{K-1} \sim p_{t_{K-1}}$
 $\pi \leftarrow \text{MMOT}(\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{K-1})$ ▷ mini-batch OT
 $t \sim \mathcal{U}[t_0, t_{K-1}]$
 $(\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(N_{\text{traj}})}) \sim \pi$ ▷ Sample trajectories
 $\boldsymbol{\mu}_t(\mathbf{z}^{(j)}) \leftarrow \text{Interpolant}(\mathbf{z}^{(j)}, t)$ ▷ Return the interpolated conditional path value at time t
 $\dot{m}_t(\mathbf{z}^{(j)}) = m_t(\mathbf{z}^{(j)})g(\mathbf{z}^{(j)})$ ▷ Run growth dynamics on trajectories
 $M_t \leftarrow \sum_{j=1}^{N_{\text{traj}}} m_t(\mathbf{z}^{(j)})$
 $\mathcal{L}_{\text{CFM}} = \mathbb{E}_{t \sim \mathcal{U}, \mathbf{z} \sim \pi} \left[\frac{m_t(\mathbf{z})}{M_t} \mathbb{E}_{p_t(\mathbf{x}|\mathbf{z})} \|\boldsymbol{\mu}'_t(\mathbf{z}) - \mathbf{u}_t^\theta(\mathbf{x})\|^2 \right]$ ▷ Compute total loss
 $\mathcal{L}_g = \sum_{k=0}^{K-1} |M_{t_k} - \widehat{M}_{t_k}|$
 $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CFM}} + \lambda_g \mathcal{L}_g$
 $\theta \leftarrow \text{Update}(\theta, \nabla_\theta \mathcal{L}_{\text{total}})$ ▷ Update θ
return $\mathbf{u}_t^\theta$

- 학습 루프 : score 사전 추정 → 미니배치로 optimal transport 궤적 $\mathbf{z}$ 샘플링 → Chebyshev interpolant로 조건부 경로 $\mu_t(\mathbf{z})$ 계산
 - → 질량 m_t 를 성장률 g 로 함께 갱신하고, $\mathcal{L}_{\text{CFM}} + \lambda_g \mathcal{L}_g$ 를 최소화하도록 θ 를 업데이트 → 수렴할 때까지 반복해 최종 velocity field $\mathbf{u}_t^\theta$ 를 얻음

Method



Probability Flow Matching (PFM)

1. Gene space 에서 직접 추론
2. force $f(x)$ 와 diffusion $D(x)$ 의 형태를 자유롭게 지정 (ODE / Langevin / CLE / additive / multiplicative)
3. ODE 반복 solve 와 Wasserstein 계산이 불필요 (Simulation-free)
4. Unbalanced 확장으로 증식·사멸까지 동시 추론

Result 2


Accurate inference of differentiation dynamics in the Hematopoietic system

- Data : **ex vivo hematopoiesis**
 - CD34+ HSPC 12일 분화, scRNA-seq day 2/4/6/8/11 (erythroid · megakaryocyte axis를 반영)
- 24개 **TF 유전자** 의 mRNA count 만으로 PCA 투영해도 시간 진행과 계통 분기가 그대로 재현되어 reduced TF space 사용




Result 2

Accurate inference of differentiation dynamics in the Hematopoietic system



1. 학습된 force field (f)로부터 Jacobian 행렬(Δ_{ij})을 유도
2. 추론된 행렬에서 각 유전자 쌍의 조절 방향과 활성화(+)/억제(-) 부호를 포함하는 상호작용 정보를 추출 → GRN
3. 실제 네트워크와 코사인 유사도로 비교




- ODE/TrajNet++ → Noise-distorted landscape
- Additive : 노이즈 크기 = 1



Result 4


Biophysically consistent models lead to accurate gene-regulatory network inference

- In such cases, one way to assess whether a model has learned the correct regulatory interactions is to evaluate its ability to generalize to unseen initial conditions



Result 5

Biophysically consistent models lead to accurate gene-regulatory network inference





Result 6

Unbalanced PFM w. Growth Dynamics

- Jointly infer both the gene-regulatory dynamics ($h(x)$) and the growth dynamics ($g(x)$) through an additional objective that penalizes deviations from the observed population imbalances
- 두 개의 유전자가 서로를 억제하는 고전적인 Toggle Switch 모델 → Ground Truth


$$\hat{\mathbf{h}}, \hat{g} = \arg \min_{\mathbf{f}, g} \mathcal{L}_{\text{CFM}} + \lambda_g \sum_k |M_{t_k} - \hat{M}_{t_k}| \quad (2)$$

(a) Genetic toggle-switch



Result 6

Unbalanced PFM w. Growth Dynamics



Summary & Discussion

Summary

- 방법론적 기여
 - (i) 임의 형태의 stochasticity 를 다루는 closed-form CFM 목적함수
 - (ii) Chebyshev 시간 보간
 - (iii) unbalanced 확장(증식·사멸)
- Intrinsic noise 를 명시한 CLE 만이 GRN 복원, OOD 일반화, KO 예측에서 모두 성공
- 표현 공간의 선택도 중요 : latent embedding 대신 **TF gene space** 가 해석 가능성과 계산 효율을 동시에 확보

Limitation

- 24개 TF 로 축소한 gene space
 - TF 선정 기준에 결과가 의존할 수 있고 non-TF 조절층(miRNA, epigenetic)은 배제
- score function 을 먼저 독립 추정 → score 오차가 drift/diffusion 추정에 그대로 전파될 여지

Discussion

- "잘 맞는 모델" 을 고르는 기준으로 interpolation error 를 쓰는 관행 자체에 대한 반례
 - held-out 성능 대신 **perturbation 예측·OOD 일반화** 를 기준으로

	PFM (Probability Flow Matching)	AnnFlux (Object-conditioned SDE)
학습 방식	Simulation-free: 미분 방정식을 풀지 않고 속도장을 직접 회귀 학습함.	Simulation-based: SDE를 직접 시뮬레이션(Euler-Maruyama)하여 종점 분포를 맞춤.
모델링 공간	유전자 공간 (TF Space): 24개 핵심 TF의 실제 발현량 공간에서 직접 작동함.	잠재 공간 (Latent Space): VAE를 통해 압축된 잠재 벡터 공간 에서 역학을 학습함.
스코어 함수 활용	사용: Fokker-Planck 방정식에 따라	미사용: 스코어 함수 x Gene/Drug 정보를 조건으로 하는 힘의 장(Drift field) 학습
목적 함수	CFM Loss: 실제 조건부 속도와 모델 예측 속도 간의 차이를 최소화	Multi-term Loss: MSE, Energy distance , Magnitude, Velocity ratio 4가지 항
시간 보간	Chebyshev 다항식: 여러 시점(Multi-marginal) 간의 전역적 매끄러움을 보장	연속 시간 시뮬레이션: 훈련 시 고정된 단계를 거쳐 특정 시간 t 로 세포를 수송